Iniciación práctica al análisis de datos OMOP

¿Cómo empezar?



Anna Palomar

apalomar@idiapjgol.org

Marzo 2025

Índice



- ¿Por dónde empiezo?
 - OHDSI
 - OHDSI Spanish node
 - ¿Dónde encajo?
- Estudios en OMOP: pasos a seguir
 - Una sola base de datos
 - Estudios en red
- Retos y buenas prácticas

¿Cómo empezar? - OHDSI



• El libro de OHDSI - http://book.ohdsi.org

- OHDS
 OBSERVATIONAL HEALTH DATA SCIENCES AND INFORMATICS
- Se mantiene y actualiza continuamente por la comunidad
- Repositorio central de conocimiento
- Contenido:
 - Comunidad OHDSI
 - Explicación CDM y vocabularios estándar
 - Herramientas de código abierto
 - Calidad de datos
 - Estudios en red

¿Cómo empezar? - OHDSI









Deberás registrarte para obtener una cuenta



OHDSI Tip: Follow topics to receive emails when new posts are added

Introduce yourself!

Let the community know you're here by introducing yourself in the forum or at a community meeting

Join an OHDSI meeting

Sit in on our weekly community meetings



Reuniones semanales Martes de 11 AM-12 PM (ET)





Join the OHDSI research network

OR

By leading a study across the network

By converting data to the OMOP Common Data Model

Join an working group

Or start your own work group!

Múltiples working groups, veamos algunos...



Provide feedback

Identify and evaluate ways to use real-world evidence to inform decision making





¿Cómo empezar? - OHDSI grupos de trabajo



Africa Chapter

<u>APAC</u>

ATLAS/WebAPI

Clinical Trials

Common Data Model

CDM Survey Subgroup

CDM Vocabulary Subgroup

Dentistry

Early-Stage Researchers

Electronic Animal Health Records

Eye Care & Vision Research

FHIR and OMOP

Generative AI & Analytics in Healthcare (GAIA)

GIS – Geographic Information System

HADES

Health Equity

Healthcare Systems

<u>Industry</u>

Latin America

Medical Devices

Medical Imaging

Methods Research

Natural Language Processing

Network Data Quality

<u>Oncology</u>

Open-Source Community

Patient-Level Prediction

Perinatal and Reproductive Health

Phenotype Development & Evaluation

Psychiatry

Rehabilitation

Registry

Steering Group

Surgery and Perioperative Medicine

Themis

Vaccine Vocabulary

¿Cómo empezar? – Simposio europeo de OHDSI







Envío abstracts - 31 Marzo 2025

¿Cómo empezar? - OHDSI Spanish Node



OHDSI Spanish Node

https://www.ohdsi-europe.org/index.php/national-nodes/spain



Dr. Talita Duarte Salles IDIAP Jordi Gol



Dr. Miguel Angel Mayer Consorci Parc de Salut Mar Barcelona (PSMAR)

¿Cómo empezar? - OHDSI Spanish Node



Objetivos

- Adoptar y promover la misión, visión y valores de OHDSI.
- 2. Facilitar la coordinación entre los miembros de la red española y con otros nodos europeos e internacionales de OHDSI.
- Contribuir a la coordinación y comunicación con las instituciones políticas nacionales.
- 4. Participar en la **comunidad de OHDSI**.

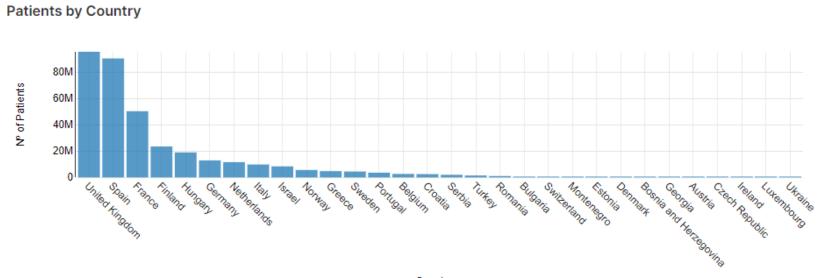
Formar parte



¿Cómo empezar? – OHDSI Spanish Node



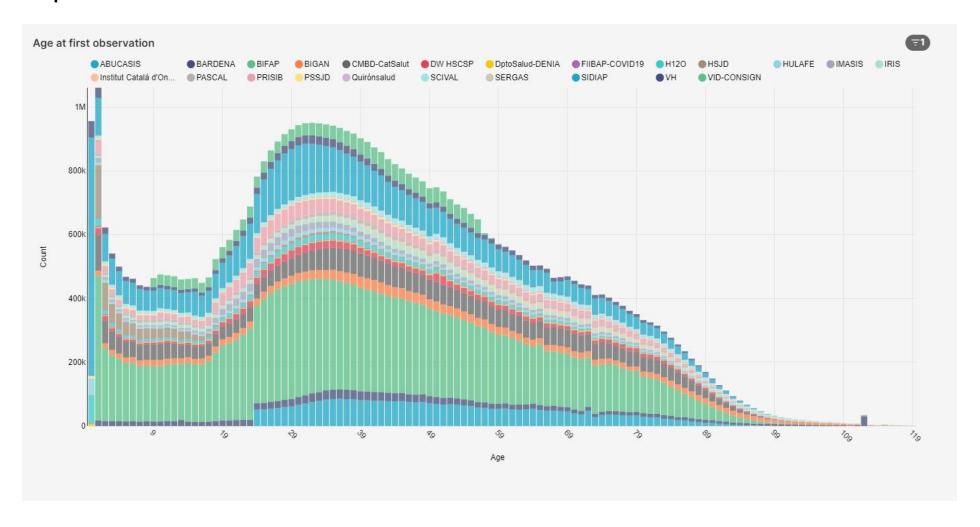
- 25 instituciones colaboradoras: servicios de salud regionales, institutos de investigación, hospitales y pequeñas y medianas empresas certificadas por EHDEN.
- Este nodo abarca registros de salud de más de 75 millones de pacientes de 15 regiones de España.



¿Cómo empezar? - OHDSI Spanish Node



• Distribución equitativa por sexo (52.7% mujeres) con una edad media de 42 años en la primera observación.



¿Cómo empezar? Enlaces de interés



Iniciación práctica al análisis de datos OMOP Grupo Real World Epidemiology 10 - 13 Marzo 2025



Enlaces de interés

Real World Data (RWD) and Common Data Models (CDM)

- Methodological Considerations when analyzing and interpreting Real-World data
 - Link to Methodological Considerations
- Common Problems, Common Data Model Solutions
 - Link to Common Data Models Solutions

¿Dónde encajo?





Mapear datos a OMOP



Aprender más sobre OHDSI y sus herramientas → EHDEN academy

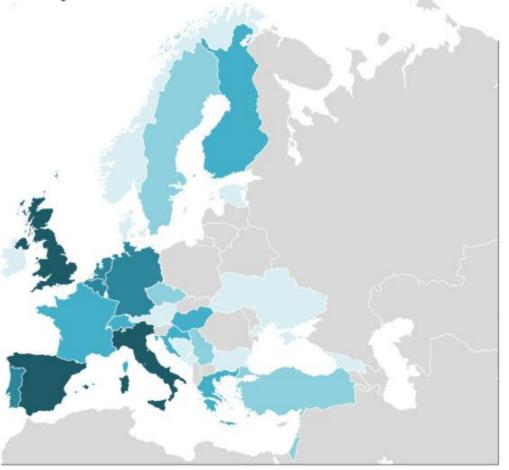
¿EHDEN?







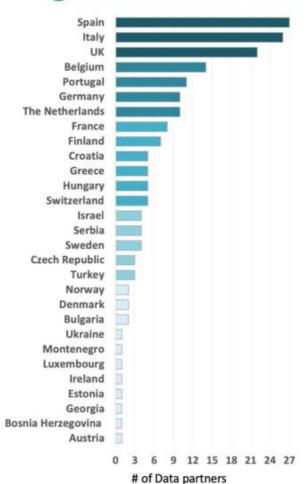




Geographic spread of data partners. The shade of blue indicates the # of data partners in that country (darker = more)







EHDEN Academy

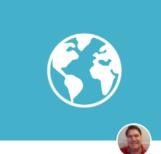




Tool

OMOP CDM and Standardised Vocabularies

The structure of the common data model and its vocabularies.



Tool

ATLAS

Design and execute analyses on observational data.



Tool

Infrastructure

Install and configure the OHDSI infrastructure.



Tool

Extract, Transform and Load

Map raw observational data to the OMOP CDM.



Tool

Introduction to Usagi & Code Mappings for an ETL

Introduction to the Usagi tool, importing codes, review and output the code mapp...



Tool

OHDSI-in-a-Box

Deploy a single instance implementation of OHDSI tools and sample data.

¿Dónde encajo?





Mapear datos a OMOP → EHDEN academy



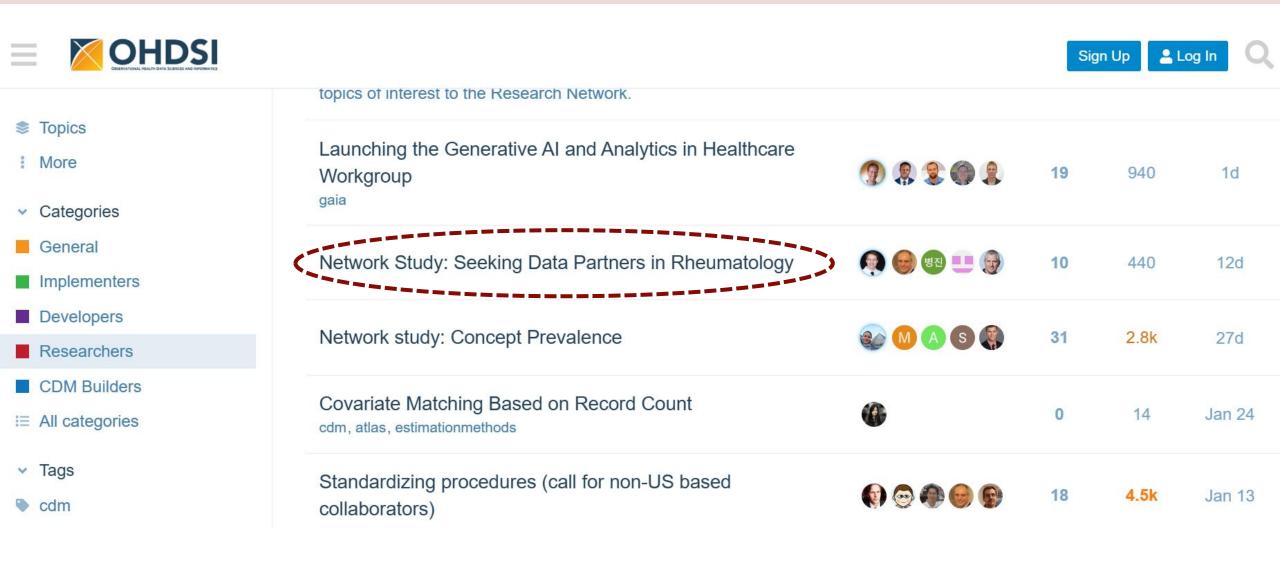
Aprender más sobre OHDSI y sus herramientas → EHDEN academy



Buscar **colaboradores** → OHDSI Researchers Topic Forum OHDSI

OHDSI Researchers Topic Forum OHDSI





¿Dónde encajo?





Mapear datos a OMOP → EHDEN academy



Aprender más sobre OHDSI y sus herramientas → EHDEN academy



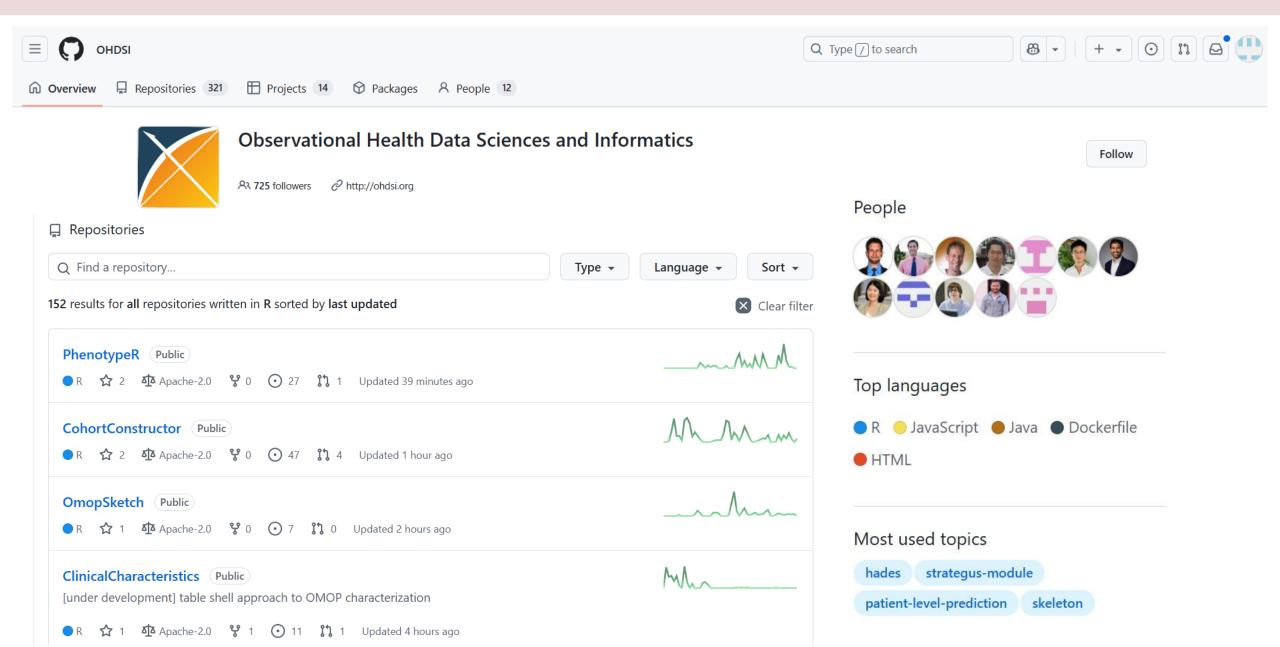
Buscar colaboradores → OHDSI Researchers Topic Forum OHDSI



Contribuir al conjunto de herramientas analíticas de OHDSI → https://github.com/OHDSI/

GitHub OHDSI





Iniciación práctica al análisis de datos OMOP

Estudios en OMOP pasos a seguir



Estudios observacionales en OMOP



- 1. Una sola base de datos
- 2. Múltiples bases de datos -> Estudios en red

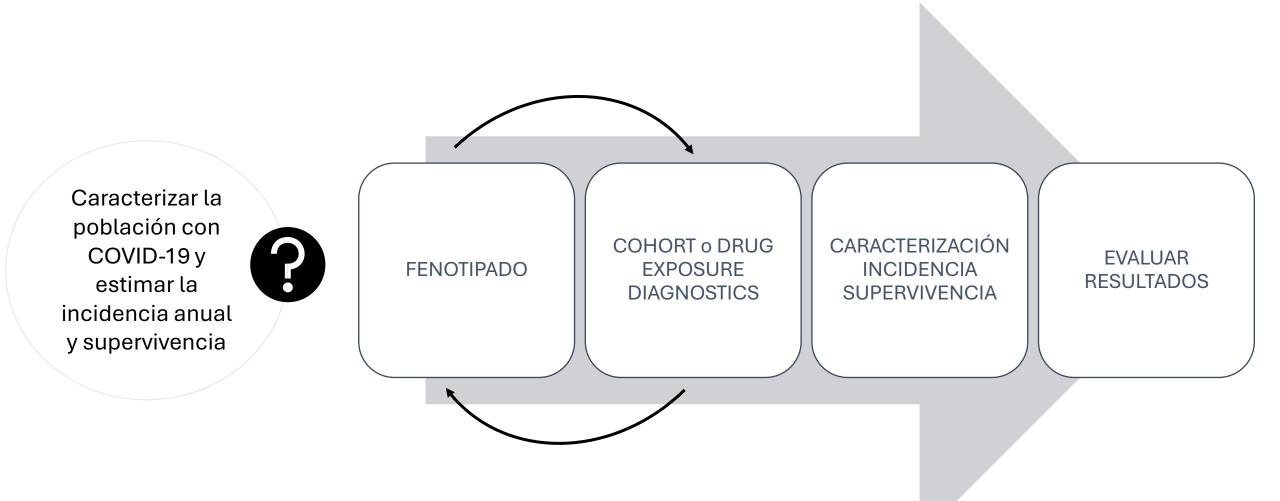
Estudios en una sola base de datos



- 1. Definir le **pregunta de investigación**
 - Caracterización: ¿Cuántos pacientes...? ¿Con qué frecuencia ...?
 - Estimación a nivel poblacional: ¿Qué tratamiento funciona mejor? ¿Cuál es el riesgo de X en Y?
 - **Predicción a nivel de paciente:** ¿Cuál es la probabilidad de que este paciente...? ¿Quiénes son candidatos para...?
- 2. Protocolo
- 3. Revisar la disponibilidad y la calidad de los datos
- 4. Definir la población de estudio
- 5. Factibilidad y diagnóstico
- 6. Ejecutar estudio
- 7. Interpretar resultados y diseminar

Flujo de trabajo





Estudios en red



¿Por qué usarlos?

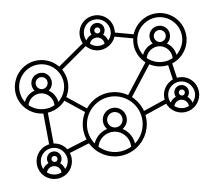
- Un estudio en una sola base de datos puede no ser suficiente, ya que los resultados pueden depender de factores específicos del grupo de pacientes (adherencia, genética, ambiente, estado de salud, etc.).
- Aumenta la diversidad de fuentes y poblaciones, evaluando si los resultados se replican en diferentes entornos.
- Identificar cómo los factores "del mundo real" afectan los hallazgos del estudio.

Un estudio se considera en red cuando el código analítico se ejecuta en distintas bases. Esto es posible gracias al mapeo a OMOP CDM.

Estudios en red



Los estudios en red de OHDSI representan la culminación de una forma **transparente**, **consistente** y **reproducible** de llevar a cabo investigaciones con **múltiples datos en todo el mundo**.



Estudios en red: cambio de paradigma



Enfoque Tradicional

- Se diseña el estudio con una base de datos específica en mente.
- Se seleccionan códigos de conceptos basándose en lo conocido del propio conjunto de datos.
- Riesgo de sesgo en la definición de cohortes al limitarse a un entorno o región específica.

Enfoque estudio en red

- El estudio se diseña para ejecutarse en múltiples sitios globales, sin acceso directo a los datos de otras instituciones.
- Solo se comparten archivos de resultados, no datos brutos.
- Se requiere una **definición de cohortes exhaustiva** para cubrir la diversidad de entornos y bases de datos (CDM).

Estudios en red: Ejemplos



Long-Term Impact of the COVID-19 Pandemic on the Incidence of Depression Diagnoses and Antidepressant Prescribing: An International Network Cohort Study from Three European Countries

25 Pages • Posted: 6 Dec 2023

Berta Raventós

Fundació Institut Universitari per a la recerca a l'Atenció Primària de Salut Jordi Gol i Gurina (IDIAPJGol)

Carlen Reyes

Fundació Institut Universitari per a la recerca a l'Atenció Primària de Salut Jordi Gol i Gurina (IDIAPJGol)

More . . .

Comparative risk of thrombosis with thrombocytopenia syndrome or thromboembolic events associated with different covid-19 vaccines: international network cohort study from five European countries and the US

BMJ 2022; 379 doi: https://doi.org/10.1136/bmj-2022-071594 (Published 26 October 2022) Cite this as: *BMJ* 2022;379:e071594

Article Open access | Published: 06 October 2020

Deep phenotyping of 34,128 adult patients hospitalised with COVID-19 in an international network study

Edward Burn, Seng Chan You, Anthony G. Sena, Kristin Kostka, Hamed Abedtash, Maria Tereza F. Abrahão, Amanda Alberga, Heba Alghoul, Osaid Alser, Thamir M. Alshammari, Maria Aragon, Carlos Areia, Juan M. Banda, Jaehyeong Cho, Aedin C. Culhane, Alexander Davydov, Frank J. DeFalco, Talita Duarte-Salles, Scott DuVall, Thomas Falconer, Sergio Fernandez-Bertolin, Weihua Gao, Asieh Golozar, Jill Hardin, ... Patrick Ryan + Show authors

Characterising the background incidence rates of adverse events of special interest for covid-19 vaccines in eight countries: multinational network cohort study

BMJ 2021; 373 doi: https://doi.org/10.1136/bmj.n1435 (Published 14 June 2021) Cite this as: *BMJ* 2021;373:n1435

The burden of post-acute COVID-19 symptoms in a multinational network cohort analysis

Kristin Kostka, Elena Roel, Nhung T. H. Trinh, Núria Mercadé-Besora, Antonella Delmestri, Lourdes Mateu, Roger Paredes, Talita Duarte-Salles, Daniel Prieto-Alhambra , Martí Català & Annika M. Jödicke

Venous or arterial thrombosis and deaths among COVID-19 cases: a European network cohort study

Edward Burn, DPhil • Talita Duarte-Salles, PhD • Sergio Fernandez-Bertolin, MSc • Carlen Reyes, PhD • Kristin Kostka, MPH • Antonella Delmestri, PhD • et al. Show all authors

Estudios en red: ¿Cómo funciona?



Colaboración entre investigadores para responder a una pregunta de investigación.

Los data partners colaboran con datos y conocimiento en el estudio.











- 1. Definir le pregunta de investigación
- 2. Protocolo
- 3. Revisar la disponibilidad y la calidad de los datos
- 4. Definir la población de estudio
- 5. Factibilidad y Diagnóstico
- 6. Finalización protocolo
- 7. Ejecutar estudio
- 8. Interpretar resultados y diseminar



- 1. Definir le pregunta de investigación
- 2. Protocolo -----
- 3. Revisar la disponibilidad y la calidad de los datos
- 4. Definir la población de estudio
- 5. Factibilidad y Diagnóstico
- 6. Finalización protocolo
- 7. Ejecutar estudio
- 8. Interpretar resultados y diseminar

Cada data partner debe pasar las regulaciones específicas (comités científicos, éticos...)



- 1. Definir le pregunta de investigación
- 2. Protocolo
- 3. Revisar la disponibilidad y la calidad de los datos



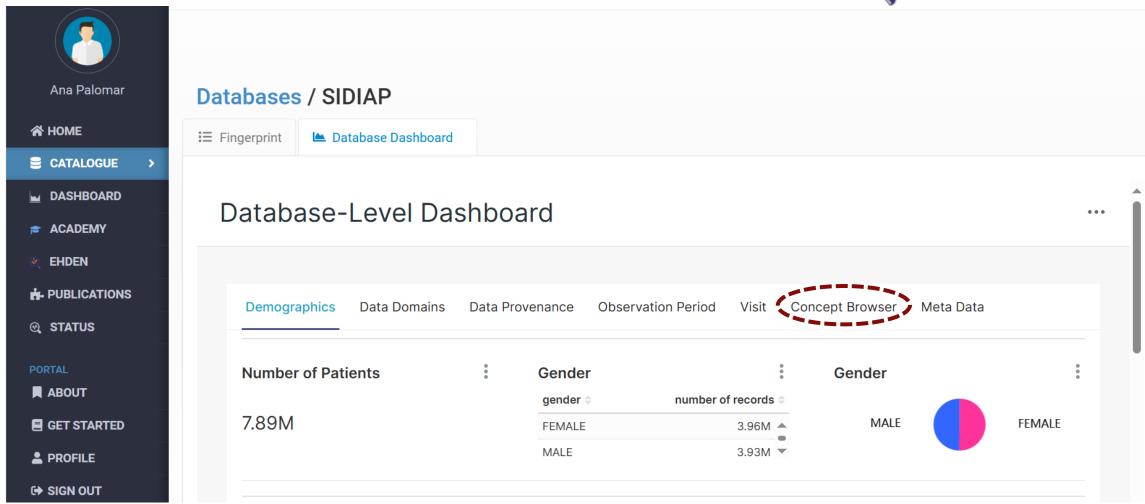
- 4. Definir la población de estudio
- 5. Factibilidad y Diagnóstico
- 6. Finalización protocolo
- 7. Ejecutar estudio
- 8. Interpretar resultados y diseminar

EHDEN



• EHDEN – portal: https://www.ehden.eu/



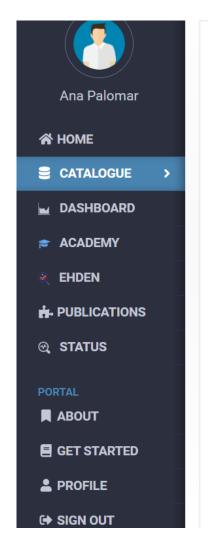


EHDEN

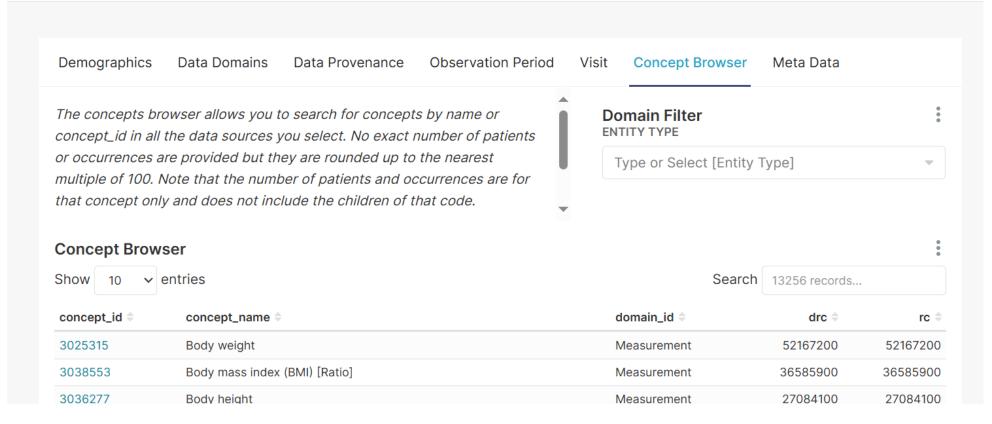


EHDEN – portal: https://www.ehden.eu/





Database-Level Dashboard





- 1. Definir le pregunta de investigación
- 2. Protocolo
- 3. Revisar la disponibilidad y la calidad de los datos
- 4. Definir la población de estudio
- 5. Factibilidad y Diagnóstico
- 6. Finalización protocolo
- 7. Ejecutar estudio
- 8. Interpretar resultados y diseminar

Estudios en red: Phenotyping



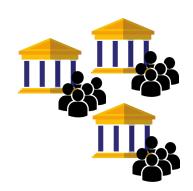


<u>Definir phenotypes</u>: Los investigadores principales hacen una **primera versión** que compartirán con los *data partners* para validarla en cada base de datos.





Ejecutar validación: Se comparte un repositorio con las definiciones de las cohortes y el código necesario (e.g. CohortDiagnostics) para **estudiar y validar cada una de las definiciones**. Cada *data partner* ejecuta el código y **revisa internamente** los resultados.



<u>Validación phenotypes</u>: Los data partners comparten los resultados con los investigadores principales. *Data partners* e IP trabajan juntos para mejorar las definiciones.

Proceso iterativo (2-3 reruns)



- 1. Definir le pregunta de investigación
- 2. Protocolo
- 3. Revisar la disponibilidad y la calidad de los datos
- 4. Definir la población de estudio
- 5. Factibilidad y Diagnóstico
- 6. Finalización protocolo
- 7. Ejecutar estudio
- 8. Interpretar resultados y diseminar

Estudios en red: Ejecución estudio





<u>Crear código analítico</u>: Los investigadores principales desarrollan el código que va a ser compartido con los *data scientist* de los centros colaboradores.





<u>Lanzar código</u>: Cada *data partner* ejecuta el código de estudio **de forma local** en su base de datos, y **revisa** los resultados de forma interna.



<u>Revisión resultados</u>: Los *data partners* comparten los **resultados agregados** (NO información a nivel individual) con los investigadores principales.

Pueden **surgir errores en el código** (e.g. distintas distribuciones de SQL), se pueden obtener resultados inesperados (e.g. diferencias en el mapeo).

Proceso iterativo (2-3 reruns)

Estudios en red: Revisión de resultados



Shiny app

For each cohort in each database comparing vaccinated with unvaccinated people, covariate balance was calculated before and after propensity score weighting, with adequate balance achieved for all covariates after weighting, except for GP practice in CPRD AURUM and CPRD GOLD (for cohorts two and three only; results are accessible in the interactive web application). Propensity scores and overlap weight distributions for the primary outcome are included in the appendix (pp 132–133). Baseline characteristics for cohorts one to four are shown in table 1 for CPRD AURUM, and in the appendix for CPRD GOLD, SIDIAP, and CORIVA (pp 16–17, 26–29, 38–41, and 48–51), with all tables showing comparability of study participants when vaccinated and unvaccinated groups were compared after weighting. Negative control outcome analyses suggested some residual confounding after weighting; therefore, in the subsequent sections we report empirically calibrated estimates and uncalibrated estimates were reported only in the web application.



Iniciación práctica al análisis de datos OMOP

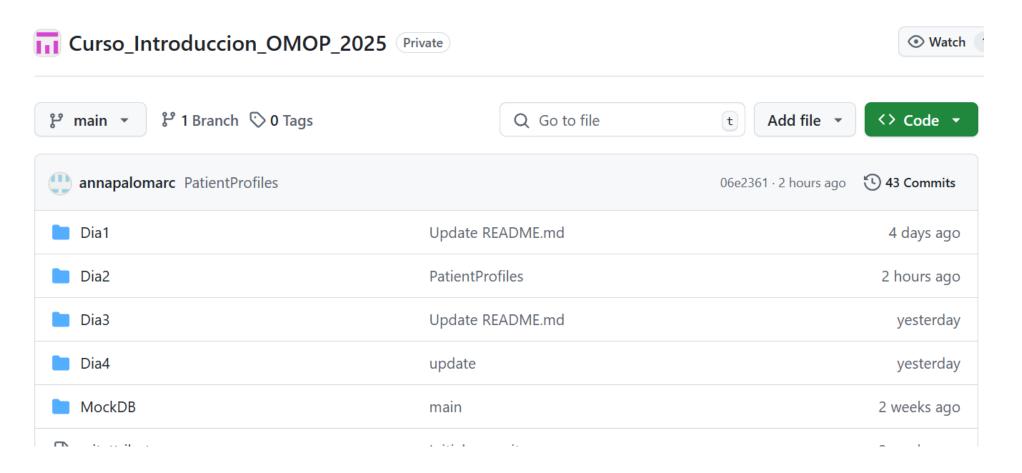
Retos y buenas prácticas





R: ¿Cómo compartir el código analítico, jsons de cohortes, shiny app, etc. ?

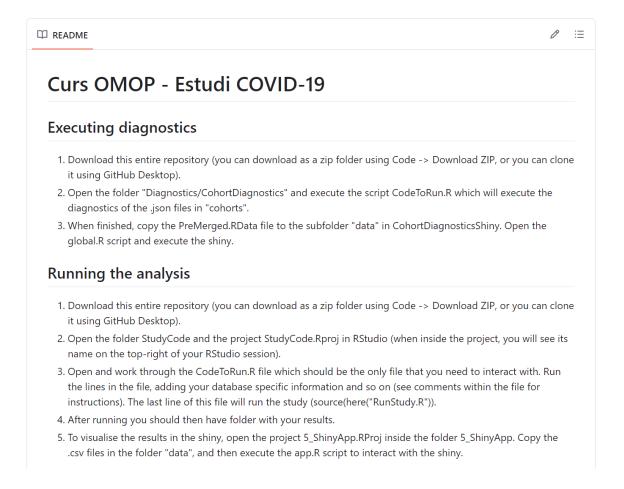
BP: Utilizar un repositorio de GitHub (como el del curso)





R: ¿Cómo guiarse dentro de un repo que te han compartido?

BP: README en el GitHub con las instrucciones para ejecutar el código.





R: ¿Cómo trabajar con un código que no has escrito tu?

BP: Tener un proyecto de R y un único script "CodeToRun" o similar que sea el único con el que se tenga que interactuar para ejecutar el código.

	cohorts	11/12/2024 11:34	Carpeta de archivos	
	concept_sets	11/12/2024 11:34	Carpeta de archivos	
>	R 2_study.Rproj	04/12/2024 11:25	Archivo RPROJ	1 KB
>	🕟 codeToRun.R	04/12/2024 11:25	Archivo R	2 KB
	README.md	04/12/2024 11:25	Archivo MD	7 KB
	renv.lock	04/12/2024 11:25	Archivo LOCK	19 KB
	RunStudy.R	04/12/2024 11:25	Archivo R	5 KB
	README.md	04/12/2024 11:25 04/12/2024 11:25 04/12/2024 11:25	Archivo R Archivo MD Archivo LOCK	2 KB 7 KB 19 KB



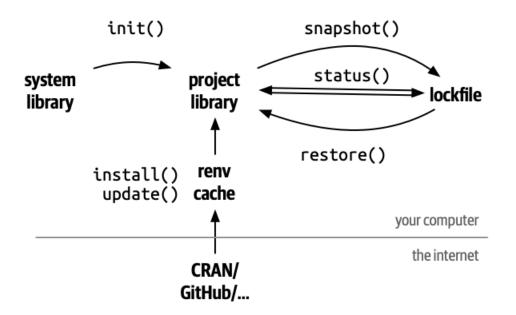
- R: ¿Cómo trabajar con un código que no has escrito tu?
- BP: CodeToRun definir las variables de R específicas de cada data partner

```
# The name/ acronym for the database
dbName <- "..."
# Database connection details
db <- dbConnect(</pre>
   RPostgres::Postgres(),
   dbname = server_dbi,
                                 Detalles de conexión a la
   port = port,
                                 base de datos
   host = host,
   user = user,
   password = password
# The name of the schema that contains the OMOP CDM with patient-level data
cdmSchema <- "..."
# A prefix for all permanent tables in the database
writePrefix <- "..."
                       Prefijo de conexión.
# The name of the schema where results tables will be created
writeSchema <- "..."
# minimum counts that can be displayed according to data governance
minCellCount <- 5
                    Numero de eventos mínimos para reportar resultados.
```



R: ¿Qué pasa con las diferentes actualizaciones y versiones de los paquetes?

BP: El paquete de R "renv" permite reproducir el entorno R del proyecto en el que se ha desarrollado el código.





R: ¿Cómo detectar el error en un código que no has escrito tu?

BP: Implementar herramientas para seguir el progreso de la ejecución código (e.g. paquete log4r).

```
1 INFO [2024-04-10 00:50:06] CREATE LOGGER
2 INFO [2024-04-10 00:50:06] STEP 0 INITIAL SETTINGS ----
3 INFO [2024-04-10 00:50:07] STEP 1 INSTANTIATE COHORTS ----
4 INFO [2024-04-10 00:50:07] - JSON cohorts
5 INFO [2024-04-10 00:50:26] - Denominator cohort
6 INFO [2024-04-10 00:51:08] STEP 2 CALCULATE INCIDENCE ----
7 INFO [2024-04-10 00:52:47] STEP 3 CHARACTERISATION ----
8 INFO [2024-04-10 00:53:15] STEP 4 SURVIVAL ----
9 INFO [2024-04-10 00:53:41] STEP 5 ZIP RESULTS ----
10 INFO [2024-04-10 00:53:42] -- DONE! --
```



R: ¿Qué pasa si...? Se detecta un error al final del código, se hacen cambios en una parte del código, se para la ejecución por algún imprevisto (corte de luz)

BP: Separar en partes independientes distintos procesos del análisis.

```
# Jobs to Run

executarInstanciarCohorts <- TRUE

executarCaracteritzacio <- TRUE

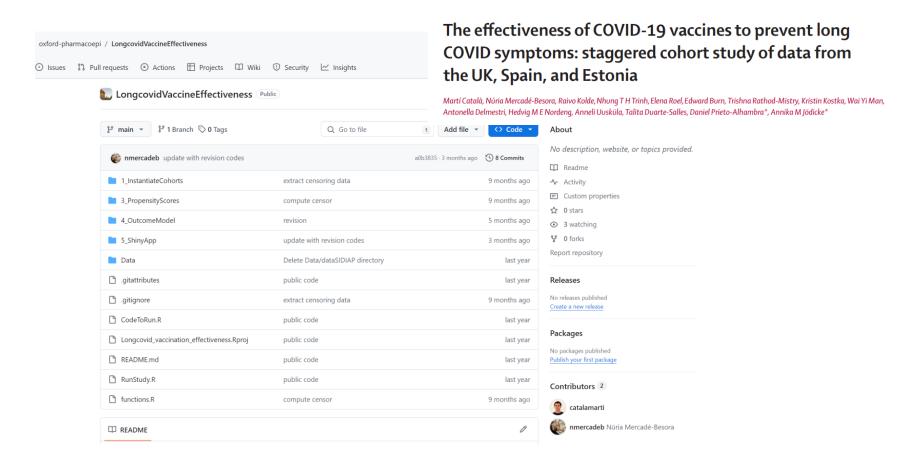
executarIncidencia <- TRUE

executarSupervivencia <- TRUE
```



R: ¿Puedo reaprovechar código analítico de estudios similares?

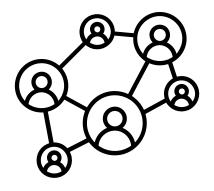
BP: Código abierto.





R: ¿Qué pasa si (cómo IP) vemos **resultados inesperados** en otra base de datos?

BP: Los *data partners* son quien mejor **conocen la base de datos** y sus **particularidades** (cómo se diagnostica cierta enfermedad en el país de origen, si el fármaco en estudio se prescribe o no, etc). Es clave el **trabajo en equipo** y la **comunicación**





R: ¿Qué pasa si (cómo IP) vemos **resultados inesperados** en otra base de datos?

BP: Es muy útil hacer un **study-a-thon**, un encuentro de 3-4 días dónde se discuten presencialmente los resultados de un estudio en red.



